บทที่ 2
ทฤษฎีและงานวิจัยที่เกี่ยวข้อง

การศึกษาทฤษฎีและงานวิจัยที่เกี่ยวข้องเป็นขั้นตอนสำคัญในการพัฒนาระบบตรวจสอบและจำแนกสภาพยางรถยนต์จากภาพถ่ายด้วยเทคโนโลยีปัญญาประดิษฐ์ (Artificial Intelligence: AI) และการเรียนรู้เชิงลึก (Deep Learning) โดยบทนี้จะกล่าวถึงแนวคิดพื้นฐานทางด้านยางรถยนต์ การประมวลผลภาพ การเรียนรู้ของเครื่อง (Machine Learning) การเรียนรู้เชิงลึก (Deep Learning) รวมถึงสถาปัตยกรรมโมเดล YOLOv11 และเครื่องมือ CVAT ที่ใช้ในการติดฉลากภาพ ตลอดจนการทบทวนงานวิจัยที่เกี่ยวข้องในสาขาใกล้เคียง เพื่อสร้างความเข้าใจในองค์ประกอบและแนวทางที่เหมาะสมสำหรับการพัฒนาระบบในงานวิจัยนี้

2.1 ทฤษฎีและหลักการ

2.1.1 ยางรถยนต์และความสำคัญของการตรวจสอบสภาพ

ยางรถยนต์ (Tire) เป็นส่วนประกอบที่สำคัญที่สุดชิ้นหนึ่งของยานยนต์ มีหน้าที่รับน้ำหนักของตัวรถและผู้โดยสาร ถ่ายทอดแรงขับ แรงเบรก และแรงเลี้ยวจากตัวรถสู่พื้นถนน ยางยังช่วยดูดซับแรงกระแทกและแรงสั่นสะเทือนจากถนน เพื่อให้การขับขี่เป็นไปอย่างนุ่มนวลและปลอดภัย

การตรวจสอบสภาพยางมีความสำคัญอย่างยิ่ง เพราะสภาพของดอกยาง (Tread) มีผลโดยตรงต่อการยึดเกาะถนนและระยะเบรก การเสื่อมสภาพหรือความเสียหายของยาง เช่น การสึกไม่สม่ำเสมอ รอยแตก รอยบวม หรือการบาดทะลุ สามารถนำไปสู่อุบัติเหตุร้ายแรงได้ การตรวจสอบยางเป็นประจำจึงเป็นส่วนหนึ่งของการบำรุงรักษาเชิงป้องกัน (Preventive Maintenance) ที่ช่วยยืดอายุการใช้งานของยางและเพิ่มความปลอดภัยของผู้ใช้รถ

อย่างไรก็ตาม การตรวจสอบยางในอู่บริการทั่วไปยังคงอาศัยการสังเกตด้วยสายตาหรือการสัมผัสโดยตรงของช่างผู้เชี่ยวชาญ ซึ่งมีข้อจำกัดในด้านความแม่นยำ ความสม่ำเสมอ และการตรวจพบความเสียหายขนาดเล็ก ระบบตรวจสอบยางด้วยเทคโนโลยี AI จึงถูกพัฒนาขึ้นเพื่อช่วยให้การตรวจสอบเป็นแบบอัตโนมัติ มีมาตรฐาน และให้ผลลัพธ์ที่เชื่อถือได้มากยิ่งขึ้น

ภาพที่ 2.1 ยางรถยนต์

2.1.2 การประมวลผลภาพ (Image Processing)

การประมวลผลภาพ (Image Processing) หมายถึง กระบวนการปรับเปลี่ยนหรือวิเคราะห์ภาพดิจิทัลโดยใช้เทคนิคทางคณิตศาสตร์และคอมพิวเตอร์ เพื่อให้ได้ภาพที่มีคุณภาพเหมาะสมสำหรับการนำไปใช้งานต่อไป เช่น การตรวจจับวัตถุ การจำแนกประเภท หรือการวัดค่าคุณสมบัติของวัตถุในภาพ

ในงานวิจัยนี้ การประมวลผลภาพถือเป็นขั้นตอนสำคัญที่ช่วยให้ระบบสามารถตรวจจับและจำแนกสภาพยางได้อย่างแม่นยำ โดยเฉพาะการทำให้รายละเอียดของลายดอกยางและรอยแตกร้าวปรากฏอย่างชัดเจนก่อนเข้าสู่การเรียนรู้ของโมเดล YOLOv11

การประมวลผลภาพแบ่งออกเป็นหลายขั้นตอนหลัก ดังนี้

2.1.2.1 การรับภาพ (Image Acquisition)

เป็นขั้นตอนแรกของกระบวนการประมวลผลภาพ โดยจะได้ภาพจากกล้องดิจิทัล สมาร์ตโฟน หรือกล้องวงจรปิด ซึ่งต้องคำนึงถึงปัจจัยแสง มุมมอง และระยะห่าง เพื่อให้ได้ภาพที่มีความคมชัดและไม่บิดเบือน สำหรับงานวิจัยนี้ ภาพยางจะถ่ายในสภาพแวดล้อมจริงของอู่ซ่อมรถ เพื่อสะท้อนการใช้งานในสถานการณ์จริง

2.1.2.2 การปรับปรุงคุณภาพภาพ (Image Enhancement)

ขั้นตอนนี้มีจุดมุ่งหมายเพื่อเพิ่มความชัดเจนของภาพ เช่น การปรับความสว่าง (Brightness) ความคมชัด (Contrast) และการลดสัญญาณรบกวน (Noise Reduction) เทคนิคที่นิยมใช้ เช่น Histogram Equalization เพื่อปรับค่าความสว่างให้สม่ำเสมอทั่วทั้งภาพ

2.1.2.3 การกรองภาพ (Filtering)

ใช้เทคนิคทางคณิตศาสตร์ เช่น Gaussian Filter หรือ Median Filter เพื่อขจัดสัญญาณรบกวนขนาดเล็ก โดยเฉพาะฝุ่นหรือจุดรบกวนจากพื้นผิวของยาง ซึ่งอาจส่งผลให้โมเดลเข้าใจผิดในการเรียนรู้ลักษณะของรอยแตก

2.1.2.4 การตรวจจับขอบ (Edge Detection)

เป็นขั้นตอนที่ใช้ระบุขอบเขตของวัตถุในภาพ เช่น ลายดอกยางหรือรอยแตก เทคนิคยอดนิยมคือ Sobel, Canny และ Laplacian ซึ่งช่วยให้ระบบมองเห็นความเปลี่ยนแปลงของค่าพิกเซลที่ชัดเจนบริเวณขอบภาพ

2.1.2.5 การแปลงภาพ (Transformation)

เพื่อให้ภาพทั้งหมดมีขนาดและมุมมองที่เหมาะสม เช่น การหมุน (Rotation) การครอบตัด (Cropping) และการปรับขนาด (Resizing) ให้อยู่ในขนาดมาตรฐาน (เช่น 640×640 พิกเซล) ก่อนนำเข้าสู่โมเดล YOLOv11

2.1.2.6 การทำให้ข้อมูลเป็นมาตรฐาน (Normalization)

ปรับค่าพิกเซลให้อยู่ในช่วง 0 ถึง 1 เพื่อให้โมเดลสามารถประมวลผลได้รวดเร็วและมีเสถียรภาพมากขึ้น

ดังนั้น การประมวลผลภาพในงานนี้ไม่เพียงแต่ทำให้ภาพมีคุณภาพที่ดีขึ้น แต่ยังช่วยลดภาระให้โมเดล Deep Learning สามารถเรียนรู้ลักษณะสำคัญของสภาพยาง เช่น รอยแตกหรือการสึกหรอได้แม่นยำมากยิ่งขึ้น

2.1.3 การเรียนรู้ของเครื่อง (Machine Learning)

การเรียนรู้ของเครื่อง (Machine Learning: ML) คือสาขาย่อยของปัญญาประดิษฐ์ที่ทำให้คอมพิวเตอร์สามารถเรียนรู้จากข้อมูลและปรับปรุงผลลัพธ์โดยไม่ต้องเขียนโปรแกรมแบบตายตัว ในอดีต ML ถูกใช้ในการจำแนกข้อมูล เช่น การคัดแยกอีเมล การทำนายราคาสินค้า หรือการวิเคราะห์แนวโน้มข้อมูล

หลักการของ ML คือ การฝึกสอนระบบให้เรียนรู้จากข้อมูลตัวอย่าง (Training Data) เพื่อสร้าง “โมเดล” ที่สามารถทำนายผลลัพธ์ใหม่ได้ โดยมีขั้นตอนหลัก 3 ขั้นตอนคือ

- การเก็บและเตรียมข้อมูล
- การสร้างโมเดลด้วยอัลกอริทึมทางคณิตศาสตร์
- การทดสอบและประเมินผลด้วยข้อมูลที่ไม่เคยเห็นมาก่อน

ตัวอย่างอัลกอริทึมของ Machine Learning ได้แก่

Decision Tree – ใช้โครงสร้างแบบต้นไม้เพื่อแบ่งกลุ่มข้อมูล

Support Vector Machine (SVM) – ใช้เส้นขอบจำแนก (Hyperplane) เพื่อแยกประเภทของข้อมูล

K-Nearest Neighbors (KNN) – จำแนกข้อมูลใหม่โดยอิงจากข้อมูลที่คล้ายกันในระยะใกล้

Random Forest – ใช้การรวมผลของ Decision Trees หลายต้นเพื่อเพิ่มความแม่นยำ

อย่างไรก็ตาม ML แบบดั้งเดิมยังมีข้อจำกัด โดยเฉพาะในการวิเคราะห์ข้อมูลเชิงภาพ เพราะต้องอาศัย “การออกแบบคุณลักษณะ (Feature Engineering)” ด้วยมือ เช่น การหาค่าความคม ความโค้ง หรือ

รูปทรง ซึ่งซับซ้อนและใช้เวลามาก ทำให้เกิดการพัฒนา “Deep Learning” ที่สามารถเรียนรู้คุณลักษณะเหล่านี้ได้โดยอัตโนมัติ

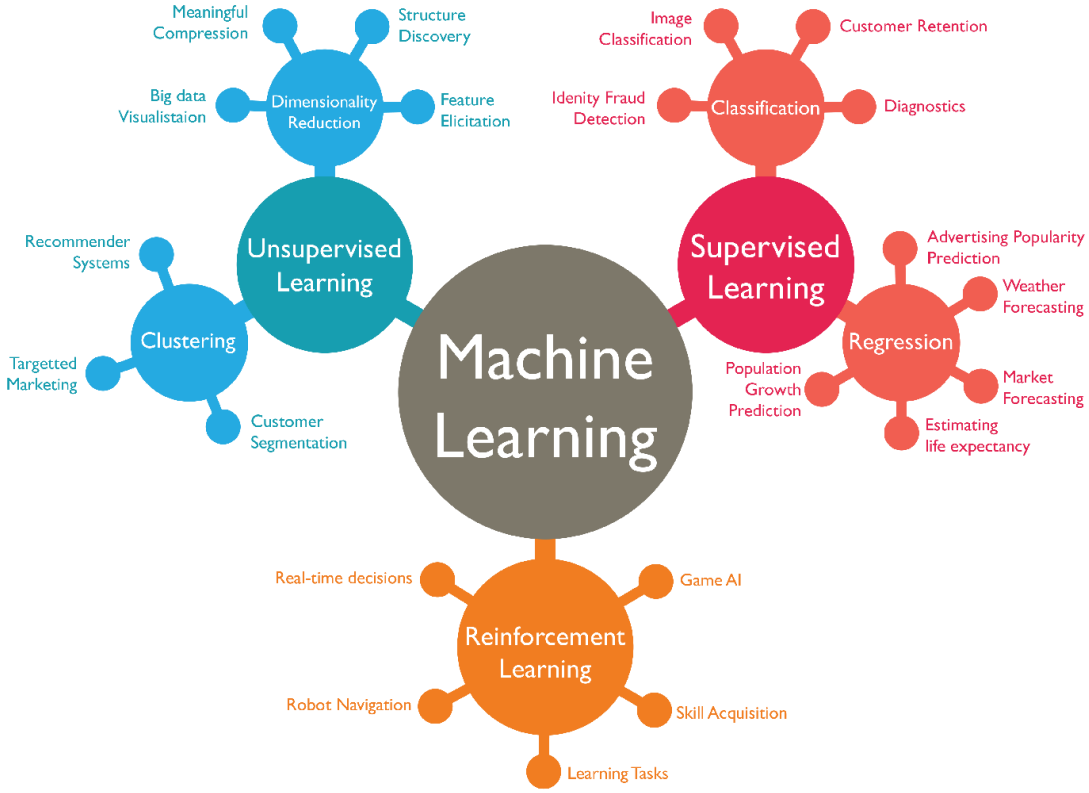

ภาพที่ 2.2 โครงสร้างการเรียนรู้ของเครื่อง (Machine Learning)

2.1.4 การเพิ่มจำนวนข้อมูล (Data Augmentation)

การเพิ่มข้อมูลภาพนั้นจากการศึกษาพบว่ามีหลากหลายเทคนิค เช่น การเพิ่มข้อมูลภาพบนพื้นฐานการเรียนรู้เชิงลึก คือ การนำภาพซ้อน ปรับแต่ง ในลักษณะต่าง ๆ หรือการเพิ่มด้วยการสังเคราะห์ภาพขึ้นมา และวิธีพื้นฐาน เช่น การแปลงด้วยวิธีเรขาคณิต การสลับซ้าย ขวา เป็นต้น การเพิ่มจำนวนรูปภาพส่วนใหญ่มุ่งเน้นในการเพิ่มจำนวนข้อมูลภาพในการฝึกฝนโมเดลให้มีความแม่นยำ ป้องกัน Overfitting ของข้อมูล ดังนั้น จึงได้สรุปวิธีการเพิ่มจำนวนข้อมูลด้วยวิธีพื้นฐาน ดังต่อไปนี้

2.1.4.1 การพลิกรูป (Flipping) เป็นการสร้างภาพเพิ่มด้วยการพลิกในแนวแกนนอน (Horizontal axis flipping) และการพลิกในแนวแกนตั้ง (Vertical axis flipping) สำหรับวิธีนี้เป็นวิธียอดนิยมและง่ายที่สุดและพิสูจน์แล้วว่าเหมาะสมกับการนำไปฝึกฝนเครือข่ายอย่าง CNNเนื่องจากยังรักษาลักษณะเด่นของภาพได้

2.1.4.2 การตัดส่วนภาพ (Cropping) การตัดภาพเป็นอีกหนึ่งวิธีที่สามารถนำมาใช้ได้ โดยการตัดภาพนั้นจะทาให้จุดศูนย์กลางของภาพเปลี่ยนไปรวมทั้งขนาดกว้าง x ยาว ด้วยหรืออาจจะเป็นในลักษณะในการสุ่มตัด หรือการลดขนาดของภาพ เช่น (800, 800) เป็น (400,400) ทำให้เกิดการผสมมิติต่าง ๆ ได้ แต่อย่างไรก็ดีก็จะส่งผลให้ภาพกลายเป็นประเภทข้อมูล
non-label preserving transformation

2.1.4.3 การหมุนรูป (Rotation) เป็นการเพิ่มองศาของภาพให้ปรับเปลี่ยนไปตามที่กาหนดซ้ายหรือขวาของภาพระหว่าง 1 ถึง 259 องศา

2.1.4.4 การเลื่อนภาพทั้งภาพไปมา (Translation)เป็นการเลื่อนภาพไปทางซ้ายหรือขวา บน และล่าง วิธีนี้ก็เป็นอีกหนึ่งวิธีที่นิยมกันมาก เนื่องจากว่าเป็นปรับเปลี่ยนตำแหน่งของวัตถุบนภาพได้หลาย ๆ แบบ จะทาให้โมเดลมีประสิทธิภาพในการตรวจหาวัตถุบนภาพที่แม่นยำมากขึ้นไปด้วย

2.1.5 การแบ่งชุดข้อมูล (Dataset)

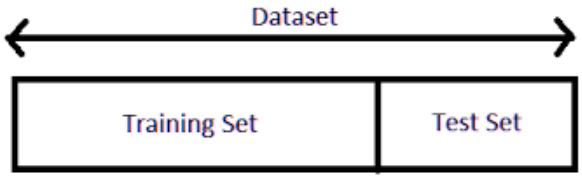

ภาพที่ 2.3 การแบ่งชุดข้อมูล (Dataset)

การเรียนรู้ของเครื่องจักร ML และการเรียนรู้เชิงลึก DL งานส่วนสำคัญอีกหนึ่งส่วนก็คือ การแบ่งชุดข้อมูล การแบ่งชุดข้อมูลมีความสำคัญต่อการฝึกฝน วิเคราะห์ และทำนายผลลัพธ์ของโมเดล โดยทั่วไปยอดนิยมจะแบ่งออกเป็น 3 ส่วนหลัก ได้แก่ เซตข้อมูลฝึกฝน (TrainingDataset) เซตข้อมูลตรวจสอบ (Validation Dataset) และเซตข้อมูลทดสอบ (Testing Dataset)

2.1.5.1 เซตข้อมูลฝึกฝน (Training Dataset) คือ เซตข้อมูลที่จะถูกนำไปใช้ในการหาค่าพารามิเตอร์ต่าง ๆ ภายในโมเดล เช่น ค่าถ่วงน้ำหนัก (Weight) ที่เป็นทั้งคุณสมบัติของข้อมูลที่เชื่อมต่อกับเครือข่ายประสาทเทียม เซตข้อมูลฝึกฝนจะเป็นตัวช่วยปรับให้เครือข่ายประสาทเทียมสามารถช่วยกำหนดคุณลักษณะต่าง ๆ (Feature selection) ได้อย่างชัดเจน

2.1.5.2 เซตข้อมูลตรวจสอบ (Validation Dataset) คือ เซตข้อมูลที่ใช้ในการช่วยปรับแต่งค่าไฮเปอร์พารามิเตอร์ของตัวจำแนกประเภทที่กาหนดไว้ในสถาปัตยกรรมของโมเดลหรือเป็นเซตข้อมูลที่ช่วยตรวจสอบความถูกต้องของโมเดลก่อนการนำไปใช้งาน (Development set)ถึงแม้ว่าการ

วัดผลความแม่นยำของเซตข้อมูลฝึกฝนจะมีความแม่นยำสูง แต่หากว่าเซตข้อมูลตรวจสอบมีความแม่นยำที่ต่ำ ก็เป็นโมเดลที่ไม่สามารถนำไปใช้งานได้ เนื่องจากโมเดลเรียนรู้เฉพาะกับเซตข้อมูลฝึกฝนเพียงเท่านั้น

2.1.5.3 เซตข้อมูลทดสอบ (Testing Dataset) เป็นชุดข้อมูลที่ไม่ได้เกี่ยวข้องหรือเป็นอิสระต่อเซตข้อมูลฝึกฝนและตรวจสอบ สาหรับเซตข้อมูลทดสอบจะถูกนำมาใช้ในการวัดประสิทธิภาพของโมเดลในงานใช้งานทั่ว ๆ ไป เช่น ภาพที่โมเดลไม่เจอเห็นมาก่อน เป็นต้น กล่าวคือเมื่อได้ผลการทำนายของโมเดลสุดท้ายการเปรียบเทียบระหว่างข้อมูลการฝึกฝนและทดสอบที่เกิดOverfitting น้อยที่สุด จะเป็นโมเดลที่มีความแม่นยำสูง

2.1.6 เครือข่ายประดิษฐ์ (Artificial Neural Networks: ANNs)

เครือข่ายประสาทประดิษฐ์(Artificial Neural Networks: ANNs) ว่า เครือข่ายประสาท (Neural Networks) หรือ เพอร์เซปตรอนหลายชั้น (Multi-Layer Perceptrons : MLPs)

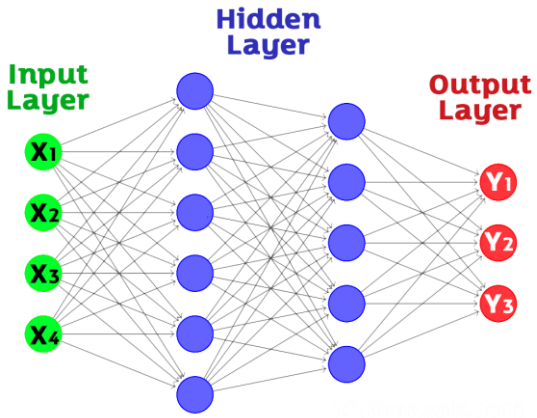

ภาพที่ 2.4 เครือข่ายประดิษฐ์ (Artificial Neural Networks: ANNs)

ชั้นอินพุต (Input Layer) เป็นชั้นที่จะนำข้อมูลเข้า โดยการนำข้อมูลเข้า จะต้องเป็นข้อมูลที่เป็นคุณลักษณะ (Feature) ของชุดข้อมูลนั้น เช่น รูปทรงเรขาคณิตที่เด่นชัด สีเฉพาะเป็นต้น

ชั้นซ่อนตัว (Hidden Layer) เป็นชั้นที่อยู่ตรงกลางระกว่างชั้น input และoutput และทำหน้าที่เป็นการเรียนรู้เชิงลึกของแบบจำลอง ในแบบจำลองนั้นไม่ได้กำหนดตายตัวว่าชั้นซ่อนนั้นจะมีกี่ชั้น สามารถที่จะกำหนดจำนวนของชั้นซ่อนได้ โดยสิ่งสำคัญในชั้นซ่อน คือ ทุกๆโหนดต้องประกอบไปด้วยฟังก์ชันไม่เชิงเส้น

ชั้นเอาต์พุต (Output Layer) จะมีความแตกต่างจากชั้นอื่น ๆ ในเครือข่ายประสาทประดิษฐ์ คือ จะไม่มีฟังก์ชันกระตุ้น เนื่องจากชั้นเอาต์พุตจะแสดงคะแนนของประเภทที่เป็นไปได้ในกรณีจำแนกประเภท (classification) หรือเป็นค่าจำนวนจริงในกรณีของการถดถอย(regression)

2.1.7 การเรียนรู้เชิงลึก (Deep Learning)

การเรียนรู้เชิงลึก (Deep Learning) เป็นเทคโนโลยีที่พัฒนาต่อจาก Machine Learning โดยใช้โครงข่ายประสาทเทียมหลายชั้น (Artificial Neural Networks: ANN) เพื่อจำลองกระบวนการคิดและการรับรู้ของสมองมนุษย์ โดยเฉพาะในการประมวลผลภาพ เสียง และข้อความ

Deep Learning สามารถ “เรียนรู้ลักษณะซ่อนอยู่” ในข้อมูลจำนวนมากได้เองโดยไม่ต้องออกแบบคุณลักษณะด้วยมือ จึงเหมาะกับงานที่ซับซ้อน เช่น การจดจำใบหน้า การตรวจจับวัตถุ การแปลภาษาอัตโนมัติ และการวิเคราะห์ภาพทางการแพทย์

สถาปัตยกรรมที่สำคัญในด้านภาพคือ Convolutional Neural Network (CNN) ซึ่งสามารถแยกแยะลักษณะภาพได้ตั้งแต่ระดับพื้นฐาน เช่น เส้น ขอบ และพื้นผิว ไปจนถึงรูปทรงของวัตถุ เช่น ดอกยาง ล้อรถ หรือรอยแตกร้าวของยาง

ข้อดีของ Deep Learning คือสามารถจัดการกับข้อมูลจำนวนมากและมีความซับซ้อนได้ดี อย่างไรก็ตาม ต้องอาศัยการประมวลผลสูง (GPU) และชุดข้อมูลจำนวนมากในการฝึกให้แม่นยำ ซึ่ง

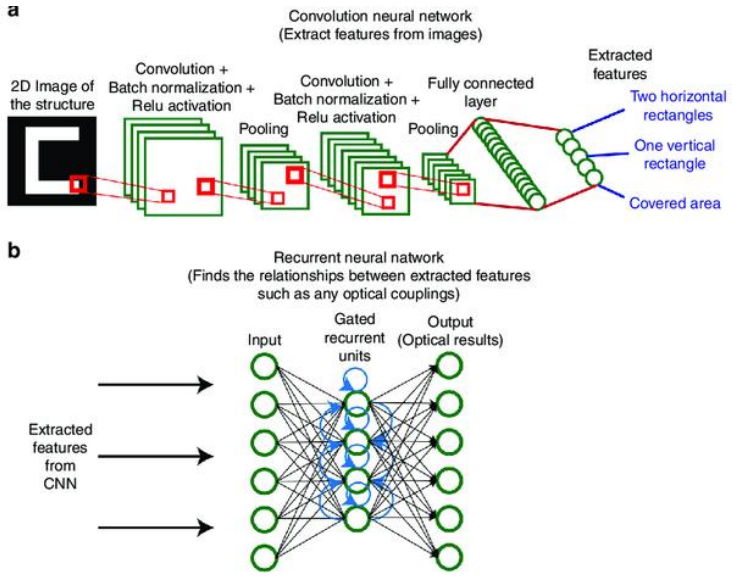

เป็นเหตุผลที่งานวิจัยนี้เลือกใช้ YOLOv11 ซึ่งเป็นโมเดล Deep Learning ที่เหมาะสำหรับภาพจำนวนมากและการทำงานแบบ Real-time

ภาพที่ 2.5 โครงสร้างการเรียนรู้ของเครื่อง (Machine Learning)

2.1.8 สถาปัตยกรรม Convolutional Neural Network (CNN)

CNN เป็นพื้นฐานของการวิเคราะห์ภาพในยุคใหม่ โครงสร้างของมันได้รับแรงบันดาลใจจากสมองมนุษย์ โดยเฉพาะเซลล์ในระบบการมองเห็น (Visual Cortex) ที่ตอบสนองต่อรูปแบบทางสายตา เช่น ขอบและลายเส้น

โครงสร้างหลักของ CNN ประกอบด้วย

Convolutional Layer – ใช้ตัวกรอง (Kernel หรือ Filter) เพื่อดึงคุณลักษณะเฉพาะ เช่น เส้นขอบ รอยแตก หรือลายดอกยาง

Pooling Layer – ทำหน้าที่ลดขนาดภาพลง (Downsampling) เพื่อให้โมเดลเรียนรู้เฉพาะส่วนที่สำคัญ เช่น Max Pooling จะเลือกค่าพิกเซลที่เด่นที่สุด

Activation Layer – ใช้ฟังก์ชัน ReLU (Rectified Linear Unit) เพื่อทำให้โมเดลเรียนรู้ความสัมพันธ์ที่ไม่เชิงเส้น

Fully Connected Layer (FC Layer) – นำคุณลักษณะที่ได้จากเลเยอร์ต่าง ๆ มาวิเคราะห์ร่วมกันเพื่อให้ผลลัพธ์สุดท้าย เช่น การบอกว่ายางอยู่ในสภาพ “ดี”, “เสื่อม”, หรือ “ชำรุด”

CNN มีประสิทธิภาพสูงในงานจำแนกภาพ และเป็นพื้นฐานของโมเดลที่ซับซ้อนกว่า เช่น YOLO, SSD และ Faster R-CNN ซึ่งถูกใช้ในงานวิจัยนี้

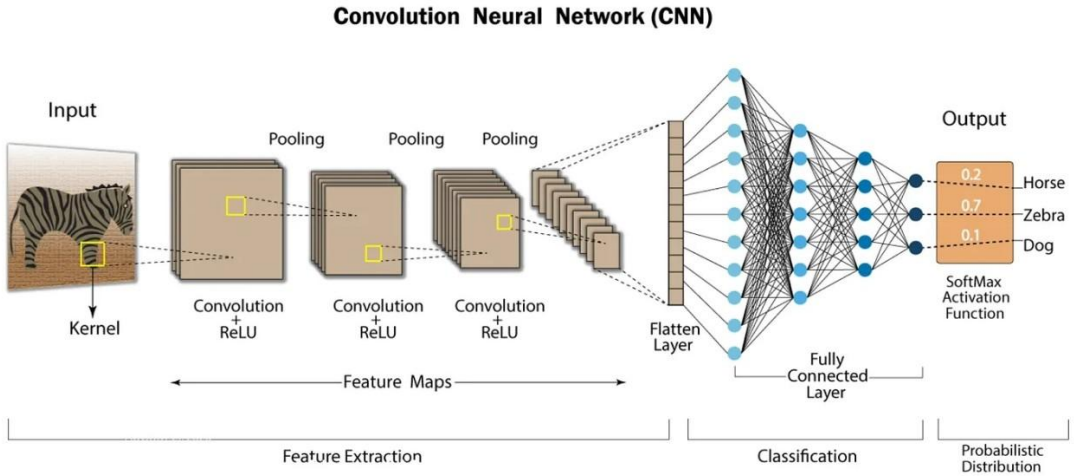

ภาพที่ 2.6 สถาปัตยกรรม Convolutional Neural Network (CNN)

2.1.9 การตรวจจับวัตถุ (Object Detection)

Object Detection เป็นขั้นตอนสำคัญของ Computer Vision ที่ใช้ในการระบุชนิดและตำแหน่งของวัตถุในภาพ โดยไม่เพียงแต่จำแนกประเภท (Classification) แต่ยังบอกตำแหน่งของวัตถุในรูปของกรอบสี่เหลี่ยม (Bounding Box) ด้วย

เทคนิคการตรวจจับวัตถุแบ่งเป็น 2 กลุ่มหลัก คือ

Two-Stage Detectors

ได้แก่ R-CNN, Fast R-CNN, และ Faster R-CNN ซึ่งใช้กระบวนการสองขั้นตอนคือ (1) การเลือกบริเวณที่อาจมีวัตถุ (Region Proposal) และ (2) การจำแนกประเภทในบริเวณนั้น ข้อดีคือมีความแม่นยำสูง แต่ใช้เวลาในการประมวลผลมาก

One-Stage Detectors

เช่น SSD (Single Shot Detector) และ YOLO (You Only Look Once) ซึ่งรวมขั้นตอนการระบุและจำแนกไว้ในกระบวนการเดียว ทำให้สามารถทำงานแบบ Real-time ได้ เหมาะกับงานที่ต้องตรวจจับอย่างรวดเร็ว เช่น การตรวจสภาพยางที่ต้องประมวลผลภาพจำนวนมากในเวลาสั้น

ในงานนี้เลือกใช้ YOLOv11 ซึ่งเป็น One-Stage Detector ที่มีความแม่นยำสูงและเหมาะสำหรับการทำงานในสภาพแวดล้อมจริงของอู่ซ่อมรถ

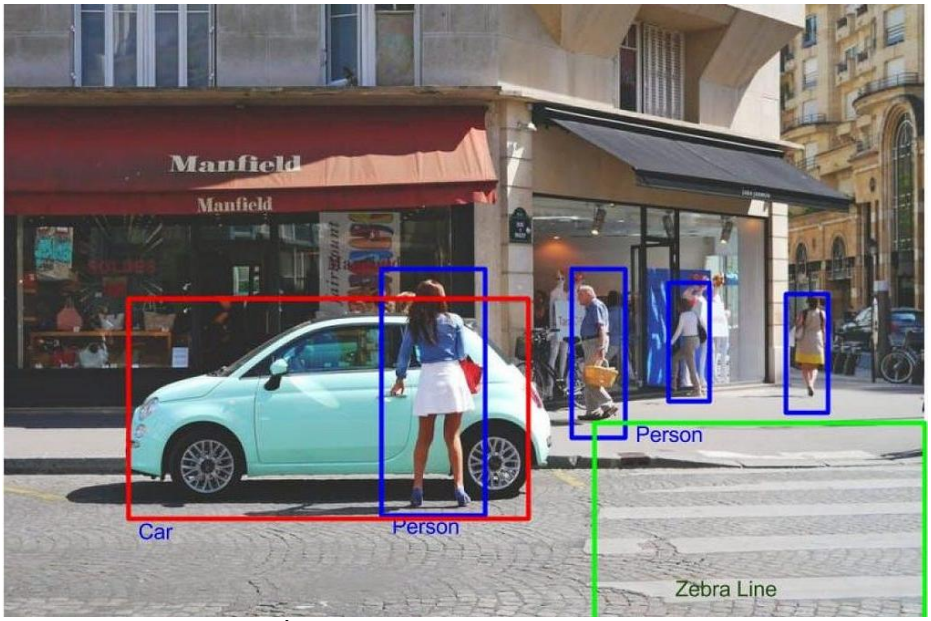

ภาพที่ 2.7 การตรวจจับวัตถุ (Object Detection)

2.1.10 สถาปัตยกรรม YOLOv11 (You Only Look Once)

YOLOv11 เป็นเวอร์ชันใหม่ล่าสุดของโมเดลตรวจจับวัตถุในตระกูล YOLO ที่พัฒนาโดย Ultralytics โดยผสานความเร็วและความแม่นยำที่สูงขึ้น YOLOv11 ใช้สถาปัตยกรรม CSPDarknet และ ELAN Backbone ที่สามารถดึงคุณลักษณะของภาพได้ละเอียดและรวดเร็วกว่า YOLO รุ่นก่อนหน้า

จุดเด่นของ YOLOv11 ได้แก่

ใช้ Anchor-free Detection ที่ไม่ต้องกำหนด anchor box ล่วงหน้า ทำให้ตรวจจับวัตถุขนาดต่าง ๆ ได้ดี รองรับการทำงานหลายขนาดโมเดล เช่น yolo11n, yolo11s, yolo11m, yolo11l, และ yolo11x ปรับปรุงโครงสร้าง Head ให้มีความแม่นยำสูงขึ้นในการทำนาย Bounding Box สามารถส่งออกโมเดลไปยังรูปแบบ ONNX, TensorRT, หรือ OpenVINO เพื่อใช้งานบนอุปกรณ์ Edge ในการวิจัยนี้จะใช้ YOLOv11s.pt ซึ่งเป็นขนาดเล็กแต่ประสิทธิภาพสูง เหมาะกับการเทรนบน Google Colab และสามารถจำแนกสภาพยางได้ทั้ง 3 ประเภท ได้แก่

- ยางสภาพดี (Normal)
- ยางเสื่อม (Bald)
- ยางชำรุด (Bad)

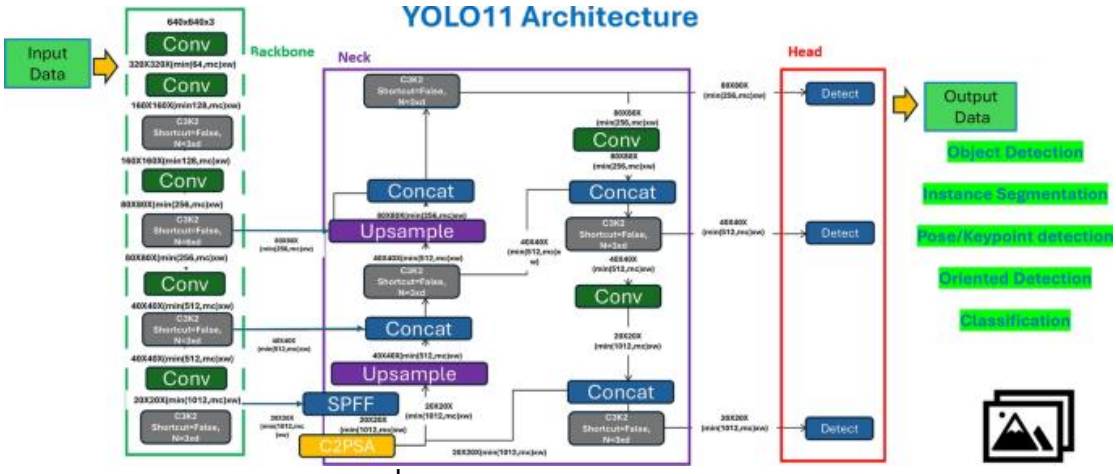

ภาพที่ 2.8 YOLOv11 (You Only Look Once)

2.1.11 การถ่ายทอดการเรียนรู้ (Transfer Learning)

Transfer Learning เป็นเทคนิคที่ช่วยให้สามารถนำโมเดลที่ถูกฝึกจากชุดข้อมูลขนาดใหญ่ (เช่น COCO Dataset) มาใช้ฝึกกับชุดข้อมูลใหม่ที่มีขนาดเล็กกว่าได้ โดยไม่ต้องเริ่มฝึกจากศูนย์ วิธีนี้เหมาะอย่างยิ่งสำหรับงานที่ข้อมูลมีจำกัด เช่น ภาพยางรถยนต์เฉพาะทาง

ขั้นตอนของ Transfer Learning ได้แก่

1. เลือกโมเดลพื้นฐานที่ผ่านการฝึกมาแล้ว (Pre-trained Model) เช่น YOLOv11s
2. ตัดบางเลเยอร์ของโมเดลออก แล้วเพิ่มเลเยอร์ใหม่สำหรับชุดข้อมูลใหม่
3. ปรับน้ำหนักเฉพาะบางส่วนของโมเดล (Fine-tuning) เพื่อให้เรียนรู้คุณลักษณะเฉพาะของยาง

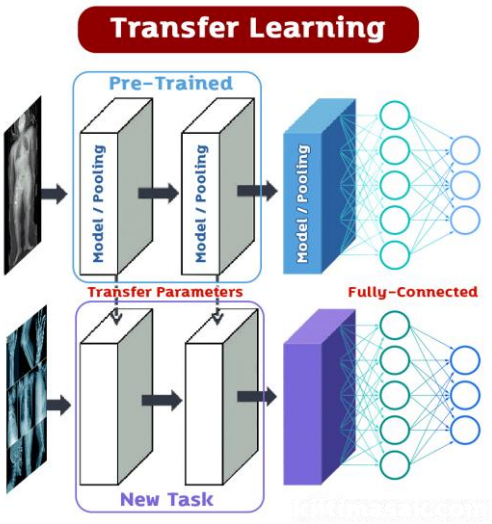

ภาพที่ 2.9 การถ่ายทอดการเรียนรู้ (Transfer Learning)

ข้อดีของเทคนิคนี้คือช่วยลดเวลาในการฝึกสอน ลดความต้องการข้อมูลจำนวนมาก และยังสามารถรักษาความแม่นยำได้สูง เหมาะกับงานวิจัยที่มีข้อมูลภาพจำกัดแต่ต้องการผลลัพธ์ที่แม่นยำ

2.1.12 เครื่องมือ CVAT (Computer Vision Annotation Tool)

CVAT เป็นเครื่องมือโอเพนซอร์สที่พัฒนาโดย Intel สำหรับใช้ในการติดฉลากข้อมูลภาพและวิดีโอในงาน Computer Vision เช่น Object Detection และ Image Segmentation

คุณสมบัติเด่นของ CVAT ได้แก่

1. รองรับการทำงานแบบ Collaborative Labeling โดยผู้ทำงานหลายคน
2. สามารถ Export/Import ข้อมูลได้ในหลายรูปแบบ เช่น YOLO, COCO, Pascal VOC
3. มีระบบตรวจสอบคุณภาพฉลาก (Review System) เพื่อควบคุมความถูกต้อง

4. สามารถทำ Model-assisted Labeling โดยใช้โมเดลที่ฝึกไว้แล้วช่วยแนะนำกรอบวัตถุอัตโนมัติ

ในงานวิจัยนี้ CVAT จะถูกใช้ในการติดฉลากภาพยางรถยนต์ 3 คลาส ได้แก่ “ยางดี (Normal)”, “ยางเสื่อม (Bald)” และ “ยางชำรุด (Bad)” ซึ่งเป็นขั้นตอนสำคัญในการสร้างชุดข้อมูลมาตรฐานสำหรับเทรน YOLOv11

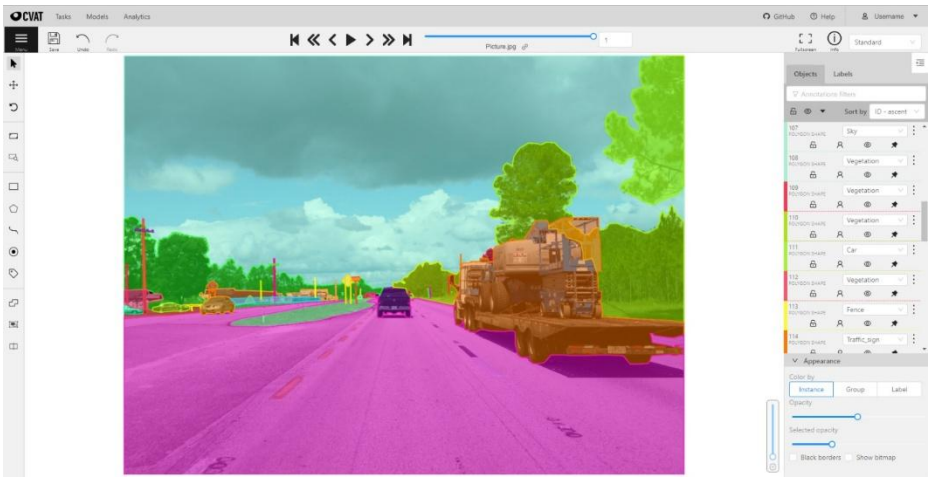

ภาพที่ 2.10 CVAT (Computer Vision Annotation Tool)

2.1.13 Google Colaboratory (Colab)

Google Colaboratory (Colab) เป็นแพลตฟอร์มออนไลน์ของ Google ที่อนุญาตให้ผู้ใช้รันโค้ด Python ได้โดยไม่ต้องติดตั้งซอฟต์แวร์ในเครื่อง และสามารถเข้าถึง GPU หรือ TPU ได้ฟรี เหมาะอย่างยิ่งสำหรับการทดลองและฝึกโมเดล Deep Learning เช่น YOLOv11

ข้อดีของ Colab ได้แก่

1. ให้บริการ GPU ฟรี เช่น NVIDIA Tesla T4 หรือ A100
2. รองรับไลบรารี AI สำคัญ เช่น PyTorch, TensorFlow, Ultralytics, OpenCV และ Matplotlib
3. สามารถเชื่อมต่อกับ Google Drive เพื่อจัดเก็บข้อมูลและผลการเทรนได้สะดวก
4. รองรับการแสดงผลกราฟ สถิติ และภาพแบบ Interactive

ในงานวิจัยนี้ Colab จะถูกใช้สำหรับการฝึกโมเดล YOLOv11s โดยใช้ชุดข้อมูลภาพยางที่ติดฉลากจาก CVAT ซึ่งช่วยให้การทดลองเป็นไปอย่างสะดวก รวดเร็ว และไม่ต้องลงทุนด้านฮาร์ดแวร์เพิ่มเติม

ภาพที่ 2.11 Logo Colab

2.2 งานวิจัยที่เกี่ยวข้อง

[1]Roomi, S. M. M. (2023). A Transfer Learning Approach for Tyre Wear Classificationได้ศึกษาวิจัยเรื่อง เสนอแนวทาง Transfer Learning สำหรับการจำแนกประเภทการสึกหรอของยาง โดยจำแนกสภาพการสึกหรอของยางออกเป็นหลายระดับ เช่น ไม่มีการสึกหรอ, สึกหรอเล็กน้อย, สึกหรอปานกลาง, สึกหรอสูง และสึกหรอมากที่สุด โดยใช้โมเดล Deep Learning ที่ฝึกมาล่วงหน้า แนวทางนี้แสดงให้เห็นถึงประสิทธิภาพในการจำแนกสภาพการสึกหรอของยาง ซึ่งเป็นอีกหนึ่งตัวอย่างของการประยุกต์ใช้ AI ในการวิเคราะห์สภาพยางที่สามารถนำมาศึกษาและพัฒนาต่อในประเทศไทยได้

[2]Roomi, S. M. M. (2023). “A Transfer Learning Approach for Tyre Wear Classification.” งานนี้นำเทคนิค Deep Learning มาจำแนกสภาพการสึกของยางโดยใช้ Transfer Learning จากโมเดล CNN ที่ผ่านการฝึกบน ImageNet พบว่าวิธีนี้ให้ความแม่นยำสูงและต้องการข้อมูลน้อย เหมาะกับงานที่ต้องจำแนกภาพยางหลากหลายแบบ ซึ่งสอดคล้องกับงานวิจัยนี้ที่ใช้ YOLOv11 พร้อม Fine-tuning เพื่อจำแนกยางดี เสื่อม และชำรุด

[3]ธนกฤต ไกรสิงห์ และ วินัย วงษ์ไทย (2566). “ระบบตรวจจับและพยากรณ์การรั่วของท่อลมในไลน์การผลิตโดยใช้เทคโนโลยี Edge Computing และ Deep Learning.”ใช้โมเดล AI ในการตรวจจับความผิดปกติในระบบอุตสาหกรรม พบว่าเทคนิค Deep Learning ช่วยให้การตรวจสอบมีความ

แม่นยำสูงและสามารถทำงานแบบ Real-time ซึ่งแนวทางนี้สามารถนำมาปรับใช้ในงานตรวจสอบยางที่ต้องวิเคราะห์สภาพจริงในอู่บริการได้โดยตรง

[4]ภัทรพล ศรีอารักษ์ และคณะ (2565). “การตรวจสอบรอยร้าวบนพื้นผิววัสดุโดยใช้ CNN.”ศึกษาการใช้ Convolutional Neural Network เพื่อตรวจหาความเสียหายบนพื้นผิววัสดุ ผลการทดลองแสดงให้เห็นว่าโมเดลสามารถตรวจจับรอยแตกได้แม่นยำกว่าเทคนิคประมวลผลภาพแบบเดิม ซึ่งแนวคิดเดียวกันสามารถนำมาประยุกต์ใช้กับการตรวจสอบรอยแตกร้าวของยางได้เช่นกัน

[5]ขอบภพ ซาเสน และ ฐิติเดช สมศรี (2567). “การพัฒนาระบบตรวจจับการสวมหมวกนิรภัยด้วยเทคโนโลยี Computer Vision และ CNN.”งานนี้ใช้เทคนิค Object Detection ในการตรวจจับหมวกนิรภัยจากภาพถ่ายของกล้อง CCTV โดยใช้ YOLO เป็นโมเดลหลัก ผลการทดลองแสดงให้เห็นถึงความสามารถในการทำงานแบบเรียลไทม์และมีความแม่นยำสูง ซึ่งสอดคล้องกับวัตถุประสงค์ของงานวิจัยปัจจุบันที่ต้องการพัฒนาระบบตรวจจับความผิดปกติของยางในเวลาอันสั้น

[6]Chowdhury, T. et al. (2022). “Automated Defect Detection in Industrial Components using YOLOv5.”ศึกษาการประยุกต์ใช้ YOLO ในงานตรวจจับตำหนิในชิ้นส่วนอุตสาหกรรม ผลการทดลองพบว่า YOLO มีความเร็วสูงและสามารถประมวลผลภาพได้แบบเรียลไทม์ เหมาะสำหรับการตรวจสอบคุณภาพชิ้นงานในโรงงาน ซึ่งเป็นแนวทางเดียวกับการตรวจสอบสภาพยางในงานนี้