บทที่ 4
ผลการดำเนินงาน

การดำเนินการวิจัยเรื่อง "การพัฒนาระบบวิเคราะห์สภาพยางรถยนต์อัจฉริยะด้วยการเรียนรู้เชิงลึก (AI Tire Check)" มีวัตถุประสงค์เพื่อศึกษาและประยุกต์ใช้อัลกอริทึมในการจำแนกสภาพยางรถยนต์ และทดสอบประสิทธิภาพความถูกต้องในการจำแนกรูปแบบความเสียหาย โดยมีผลการดำเนินงานดังนี้:

4.1 การเตรียมชุดข้อมูล

4.1.1 การเตรียมชุดข้อมูลที่ใช้ในการทดสอบ

การเตรียมชุดข้อมูลเป็นขั้นตอนสำคัญในกระบวนการพัฒนาระบบการเรียนรู้เชิงลึก เนื่องจากคุณภาพและความสมบูรณ์ของข้อมูลส่งผลโดยตรงต่อประสิทธิภาพของแบบจำลองที่พัฒนา ในส่วนนี้จะอธิบายถึงวิธีการรวบรวม จัดการ และปรับแต่งข้อมูลชุดทดสอบที่ใช้ในงานวิจัย โดยเน้นการคัดเลือกภาพถ่ายยางรถยนต์ (Tire) ที่เหมาะสม การแบ่งประเภทของข้อมูล รวมถึงกระบวนการเตรียมข้อมูลให้พร้อมสำหรับการนำเข้าสู่แบบจำลอง ทั้งนี้เพื่อให้มั่นใจว่าข้อมูลที่ใช้มีความถูกต้องและเหมาะสมสำหรับการทดสอบและการวิเคราะห์ผลลัพธ์ในขั้นตอนต่อไป โดยภายในงานวิจัยชิ้นนี้ผู้วิจัยได้จัดแบ่งชุดข้อมูลออกมาได้ดังภาพที่ 4.1

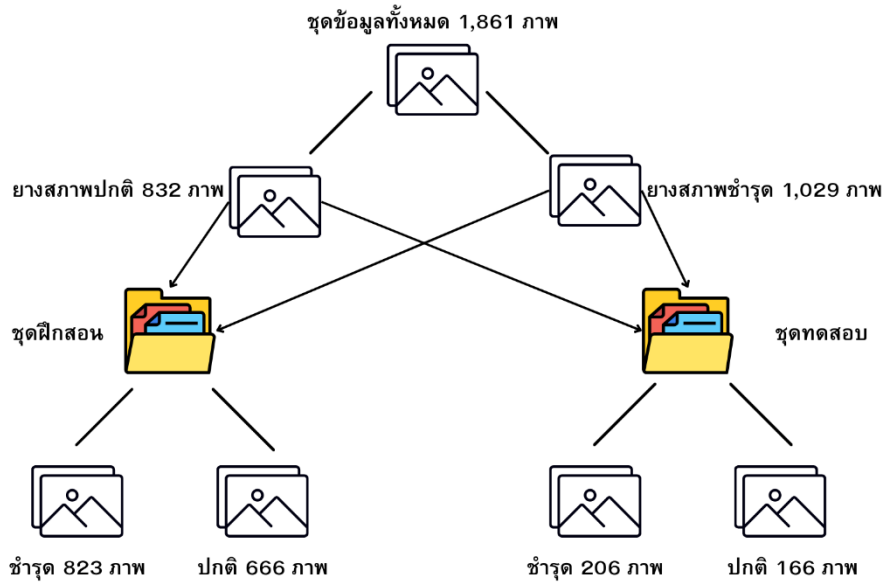

ภาพที่ 4.1 โฟลเดอร์ที่จัดเก็บชุดข้อมูล

เพิ่มตัวอย่างภาพของแต่ละclass

จากภาพที่ 4.1 โฟลเดอร์ที่จัดเก็บชุดข้อมูล แสดงถึงวิธีการแบ่งชุดข้อมูล โดยชุดข้อมูลนี้ประกอบไปด้วยภาพยางรถยนต์จำนวน 1,861 ภาพ โดยสามารถแบ่งภาพออกมาได้เป็น 2 กลุ่มหลักคือ ชุดภาพยางสภาพปกติ และชุดภาพยางสภาพชำรุด จากนั้นผู้วิจัยได้นำภาพในแต่ละกลุ่มมาทำการแบ่งสัดส่วนข้อมูล โดยจัดสรร 80% ของภาพในแต่ละกลุ่มสำหรับใช้เป็นชุดข้อมูลในการฝึกสอน (Training Set) และอีก 20% สำหรับใช้เป็นชุดข้อมูลในการทดสอบ (Validation Set) ดังแสดงในโค้ดด้านล่างในภาพที่ 4.2 หน้าโค้ดนำไปใส่ในภาคผนวก

```
# การเตรียมข้อมูลด้วย ImageDataGenerator (80% Train, 20% Validation)
datagen = ImageDataGenerator(
    rescale=1./255,
    validation_split=0.2,     # จัดสรร 20% สำหรับการทดสอบ
    rotation_range=20,
    horizontal_flip=True
)

train_generator = datagen.flow_from_directory(
    DATASET_PATH,
    target_size=(224, 224),   # ปรับขนาดภาพให้เป็น 224x224 พิกเซล
    batch_size=32,
    class_mode='binary',
    subset='training'
)

val_generator = datagen.flow_from_directory(
    DATASET_PATH,
    target_size=(224, 224),
    batch_size=32,
    class_mode='binary',
    subset='validation'
)
```

ภาพที่ 4.2 โค้ดการสร้างชุดข้อมูลสำหรับฝึกสอนและชุดข้อมูลทดสอบ

จากภาพที่ 4.2 โค้ดนี้แสดงให้เห็นขั้นตอนการสร้างชุดข้อมูลสำหรับฝึกสอนและชุดข้อมูลทดสอบ โดยแบ่งสัดส่วน 80:20 ตามลำดับ และมีการปรับขนาดภาพให้เป็น 224x224 พิกเซล เพื่อความสม่ำเสมอในการนำเข้าโมเดล

4.1.2 การสร้าง Data Augmentation

เนื่องจากชุดข้อมูลภายในงานวิจัยชิ้นนี้มีจำนวน 1,856 ภาพ การทำ Data Augmentation จึงเป็นเทคนิคสำคัญที่ช่วยเพิ่มความหลากหลายของจำนวนข้อมูลที่มีอยู่ โดยการปรับเปลี่ยนภาพต้นฉบับในลักษณะต่างๆ เช่น การหมุน (Rotation), การเลื่อน (Shift), การบิด (Shear) และการซูม (Zoom) ซึ่งเป็นวิธีที่มีประสิทธิภาพในการแก้ปัญหาความหลากหลายของข้อมูลและช่วยลดการเกิด Overfitting โดยภายในงานวิจัยชิ้นนี้ได้มีการทำ Data Augmentation จำนวน 6 รูปแบบ ดังภาพที่ 4.3

ภาพที่ 4.3 การทำ Data Augmentation รูปแบบต่างๆ ของข้อมูลยางรถยนต์

```
# การกำหนดคุณสมบัติการเพิ่มข้อมูล (Augmentation Parameters)
datagen = ImageDataGenerator(
    rescale=1./255,            # ปรับช่วงค่าสีพิกเซลเป็น 0-1
    rotation_range=20,         # การหมุนภาพสุ่ม
(Rotation)
    width_shift_range=0.2,     # การเลื่อนภาพแนวนอน
(Width Shift)
    height_shift_range=0.2,    # การเลื่อนภาพแนวตั้ง
(Height Shift)
    shear_range=0.2,           # การเฉือน/บิดภาพ (Shear)
    zoom_range=0.2,            # การซูมภาพ (Zoom)
    horizontal_flip=True,       # การพลิกภาพแนวนอน
(Horizontal Flip)
    validation_split=0.2       # แบ่งข้อมูล 20% ไว้สำหรับ
ทดสอบความถูกต้อง
)
```

ภาพที่ 4.4 โค้ดการกำหนดคุณสมบัติ Data Augmentation

จากภาพที่ 4.4 โค้ดข้างต้นผู้วิจัยได้ทำ Data Augmentation จำนวน 6 รูปแบบ ได้แก่ การหมุนภาพ, การเลื่อนแนวตั้งและแนวนอน, การบิดภาพ, การซูม และการพลิกภาพ เพื่อนำมาใช้ปรับเปลี่ยนภาพต้นฉบับก่อนการประมวลผลในทุกๆ Epoch ของการฝึกสอนโมเดล เพื่อเพิ่มประสิทธิภาพในการเรียนรู้และป้องกันปัญหา Overfitting

4.2 การทดลอง

4.2.1 การวัดประสิทธิภาพของ pre-trained model กับการจำแนกสภาพยาง

ภายในงานวิจัยชิ้นนี้ได้มีการนำแนวคิด Transfer Learning มาใช้งาน ด้วยเหตุที่ชุดข้อมูลที่ผู้วิจัยได้นำมาประกอบการทดลองมีความซับซ้อนและต้องการความแม่นยำสูง เพื่อแก้ปัญหาดังกล่าวผู้วิจัยได้ประยุกต์ใช้แนวคิด Transfer Learning โดยนำแบบจำลองที่ผ่านการฝึก Pre-trained Model บนฐานข้อมูล ImageNet มาเป็นต้นแบบให้กับการเรียนรู้ของแบบจำลองในการตรวจจับสภาพยางรถยนต์ (AI Tire Check) โดยมีกระบวนการในการใช้งาน Pre-trained Model ดังที่แสดงในภาพที่ 4.5

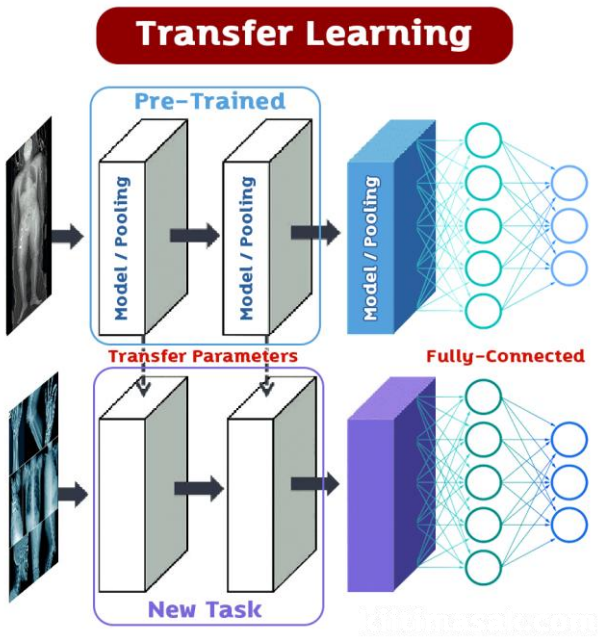

ภาพที่ 4.5 กระบวนการนา pre-trained model มาใช้งาน

จากภาพที่ 4.5 แสดงให้เห็นกระบวนการในการนำแบบจำลองที่ผ่านการฝึกฝนมาแล้ว (Pre-trained Model) มาใช้สำหรับการดึงคุณลักษณะสำคัญ (Feature Extraction) จากข้อมูล โดยมีชั้น (layers) ของแบบจำลองจะทำหน้าที่เรียนรู้รูปแบบทั่วไป เช่น ขอบ รูปทรง หรือพื้นผิว ซึ่งข้อมูลดังกล่าวจะถูกนำมาใช้เป็นข้อมูลตั้งต้นสำหรับการพัฒนาต่อเพื่อการจำแนกประเภทข้อมูล ในการวิจัยครั้งนี้ มีการใช้ Pre-trained Model จำนวน 3 สถาปัตยกรรม ได้แก่ EfficientNetV2B0, MobileNetV2 และ ResNet50V2 เพื่อเปรียบเทียบประสิทธิภาพของแบบจำลองแต่ละตัว ทั้งนี้รายละเอียดของแบบจำลองทั้ง 3 สถาปัตยกรรมได้แสดงไว้ในตารางที่ 4.1

ตารางที่ 4.1 แสดงถึงความแตกต่างระหว่าง Pre-trained Model ที่นำมาทดสอบ

โมเดล	จำนวนพารามิเตอร์(ล้าน)	ขนาดอินพุต (Pixel)	ความลึกของโมเดล(Layer)
MobileNetV2	3.5	224x224	88
EfficientNetV2B0	7.1	224x224	270
ResNet50V2	25.6	224x224	190

จากตารางที่ 4.1 แสดงถึงความแตกต่างระหว่างแบบจำลองแต่ละสถาปัตยกรรม ที่นำมาใช้เป็น Pre-trained Model โดยในแต่ละแบบจำลองจะมีรายละเอียดดังนี้:

MobileNetV2 มีจำนวนพารามิเตอร์ประมาณ 3.5 ล้านพารามิเตอร์ ซึ่งถือว่าเป็นโมเดลขนาดเล็กที่ออกแบบมาเพื่อใช้งานบนอุปกรณ์เคลื่อนที่หรืออุปกรณ์ที่มีทรัพยากรจำกัด ขนาดอินพุตอยู่ที่ 224x224 พิกเซล ความลึกของโมเดล 88 เลเยอร์ เหมาะสำหรับงานที่ต้องการความเร็วในการประมวลผลสูง (Real-time) และประหยัดหน่วยความจำ เช่น ระบบการตรวจโหมดออนไลน์ผ่านอุปกรณ์พกพาหรือระบบ IoT

EfficientNetV2B0 มีจำนวนพารามิเตอร์ประมาณ 7.1 ล้านพารามิเตอร์ เป็นสถาปัตยกรรมที่ถูกพัฒนาให้มีความแม่นยำสูงขึ้นในขณะที่ยังรักษาความเร็วในการประมวลผล ขนาดอินพุตอยู่ที่ 224x224 พิกเซล ความลึกของโมเดล 270 เลเยอร์ มีจุดเด่นด้านการประหยัดทรัพยากรสำหรับการฝึกสอน เหมาะสำหรับงานจำแนกภาพถ่ายทั่วไปที่มีความสมดุลระหว่างประสิทธิภาพและความเร็ว

ResNet50V2 มีจำนวนพารามิเตอร์ประมาณ 25.6 ล้านพารามิเตอร์ ขนาดอินพุต 224x224 พิกเซล ความลึกของโมเดล 190 เลเยอร์ โดยใช้โครงสร้างแบบ Residual Learning ที่ช่วยให้โมเดลสามารถเรียนรู้องค์ประกอบที่มีความซับซ้อนได้ดียิ่งขึ้นโดยไม่เกิดปัญหาการจางหายของข้อมูลเมื่อโมเดลมีความลึก เหมาะสำหรับงานที่ต้องการความแม่นยำในการคัดกรองตำหนิหรือความผิดปกติของวัตถุที่มีรายละเอียดพื้นผิวซับซ้อน ดังเช่นสภาพเนื้อยางรถยนต์

จากข้อมูลที่นำเสนอข้างต้น ผู้วิจัยเห็นว่าแบบจำลอง ResNet50V2 มีแนวโน้มที่จะให้ผลลัพธ์ที่ดีที่สุดเมื่อเปรียบเทียบกับแบบจำลองอื่นๆ ในการวิจัยชิ้นนี้ สำหรับขั้นตอนถัดไปจะดำเนินการนำแบบจำลองดังกล่าวมาประยุกต์ใช้เพื่อประเมินประสิทธิภาพและความแม่นยำในการทำงานต่อไป

4.2.2 การนำ pre-trained model มาประยุกต์ใช้

ในขั้นตอนนี้ผู้วิจัยได้นำโมเดล ResNet50V2 มาเป็น base model ในการพัฒนาโมเดลที่สามารถจำแนกสภาพยางได้ โดยมีโครงสร้างการทำงานดังภาพที่ 4.6

```
# โครงสร้างการเชื่อมต่อเลเยอร์ (Model Architecture)
base_model = ResNet50V2(weights='imagenet',
include_top=False, input_shape=(224, 224, 3))
base_model.trainable = False  # Freeze น้ำหนักจาก
ImageNet

model = Sequential([
    base_model,
    GlobalAveragePooling2D(),
    Dense(128, activation='relu'),
    Dropout(0.5),
    Dense(1, activation='sigmoid')
])
```

ภาพที่ 4.6 โค้ดการรับค่าและกำหนดเลเยอร์ของแบบจำลอง

จากภาพที่ 4.2 แสดงให้เห็นถึงลำดับขั้นตอนการทำงานเชื่อมต่อระหว่าง Pre-trained Model เข้ากับแบบจำลอง โดยมีรายละเอียดการทำงานในแต่ละเลเยอร์ดังต่อไปนี้:

4.1.2.1 Input layer

เป็นการกำหนดเลเยอร์อินพุตเพื่อให้รับภาพที่มีขนาด (224 x 224 x 3) พิกเซล ประกอบด้วยความกว้าง 224 พิกเซล, ความสูง 224 พิกเซล และภาพสี 3 Channels (R,G,B) โดยขั้นตอนนี้ทำให้โมเดลทราบรูปร่างของข้อมูลเริ่มต้นที่ส่งเข้ามา

4.1.2.2 base model layer

โหลดสถาปัตยกรรมหลักคือ ResNet50V2 โดยนำเลเยอร์ส่วน Classification ด้านบนของโมเดลเดิมออก และทำการ Freeze น้ำหนักในเลเยอร์ส่วนใหญ่ เพื่อรักษาคุณลักษณะ (Features) ที่ได้จากการฝึกบน ImageNet ไม่ให้ถูกอัปเดตเร็วเกินไป ช่วยลดโอกาสการเกิด Overfitting เมื่อจำนวนข้อมูลมีไม่มาก

4.1.2.3 Global Average Pooling layer

เปลี่ยนผลลัพธ์ที่อยู่ในรูป (สูง x กว้าง x Channels) ให้กลายเป็นเวกเตอร์ 1 มิติ โดยการหาค่าเฉลี่ยของแต่ละ Channel ช่วยลดจำนวนพารามิเตอร์ลงและยังรักษาข้อมูลจากแต่ละ Channel ได้อย่างมีประสิทธิภาพ

4.1.2.4 Dense layer

เพิ่มเลเยอร์แบบ Dense ขนาด 128 หน่วยพร้อมใช้ ReLU activation เพื่อให้โมเดลสามารถเรียนรู้คุณลักษณะเชิงลึกเพิ่มเติม หลังจากผ่านการสกัดคุณลักษณะจาก Base Model มาแล้ว

4.1.2.5 Dropout layer

สุ่มดรอป (Drop) โหนด 50% ในเลเยอร์นี้ เพื่อช่วยป้องกันการเกิด Overfitting โดยเฉพาะอย่างยิ่งในกรณีที่ชุดข้อมูลมีจำนวนจำกัด ทำให้โมเดลมีความสามารถในการ Generalize ได้ดียิ่งขึ้น

4.1.2.6 Output layer (Dense layer)

เลเยอร์สุดท้ายใช้ Dense ขนาด 1 หน่วยพร้อม Sigmoid activation ทำหน้าที่คำนวณค่าความเป็นไปได้ (Probability) ในการจำแนกภาพออกเป็น 2 ประเภท คือ ยางสภาพชำรุด (Defective) และยางสภาพปกติ (Good)

ผลการทดลอง

ภาพที่ 4.5 แผนภูมิแสดงความแม่นยำของ MobileNetV2

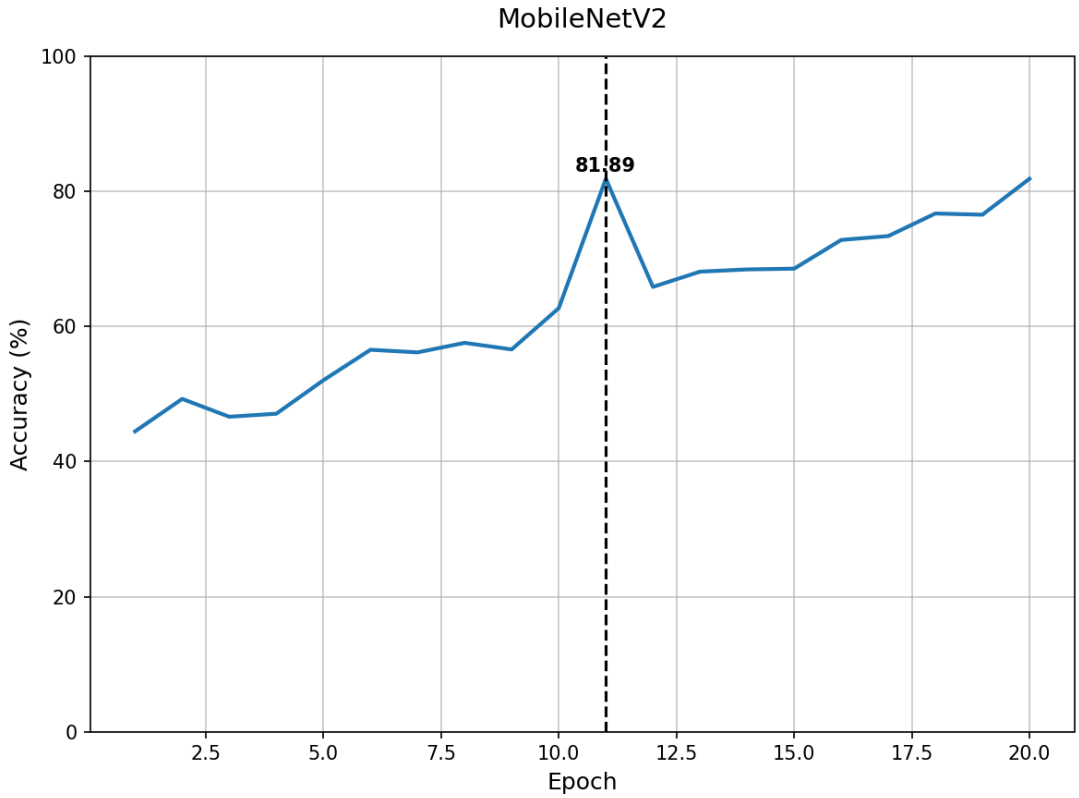

ภาพที่ 4.6 แผนภูมิแสดงความแม่นยำของ EfficientNetV2B0

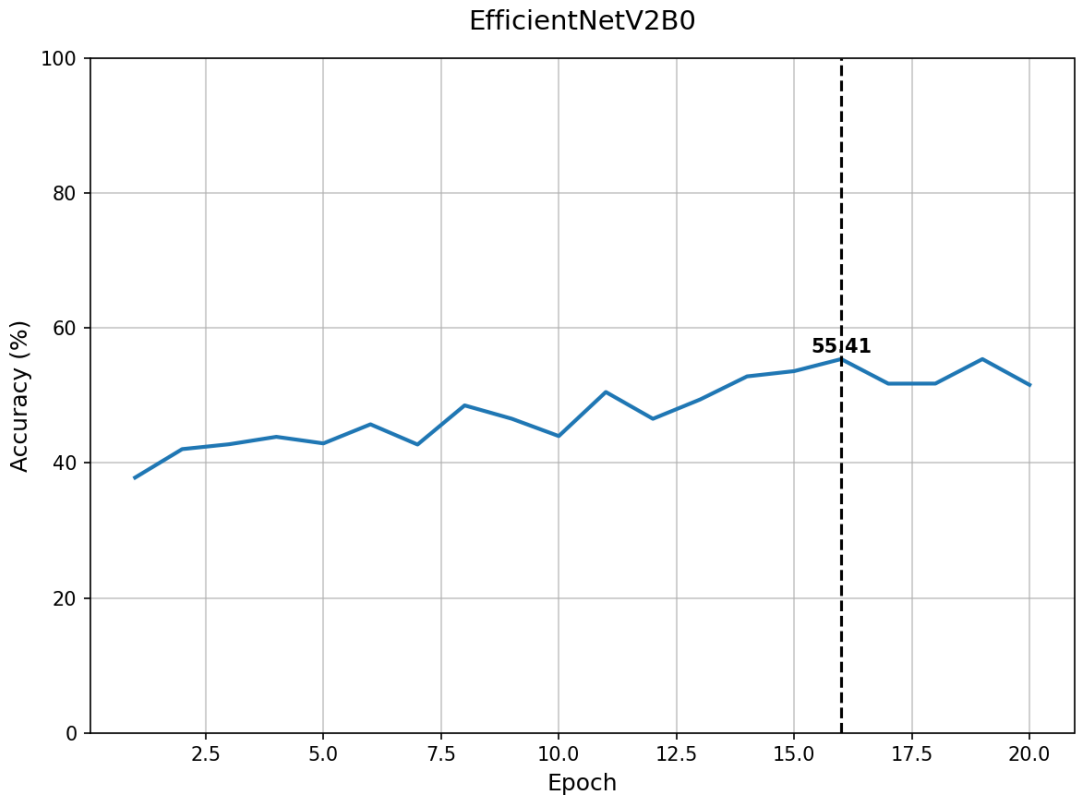

แผนภูมิแสดงความแม่นยำของ ResNet50V2 (Baseline)

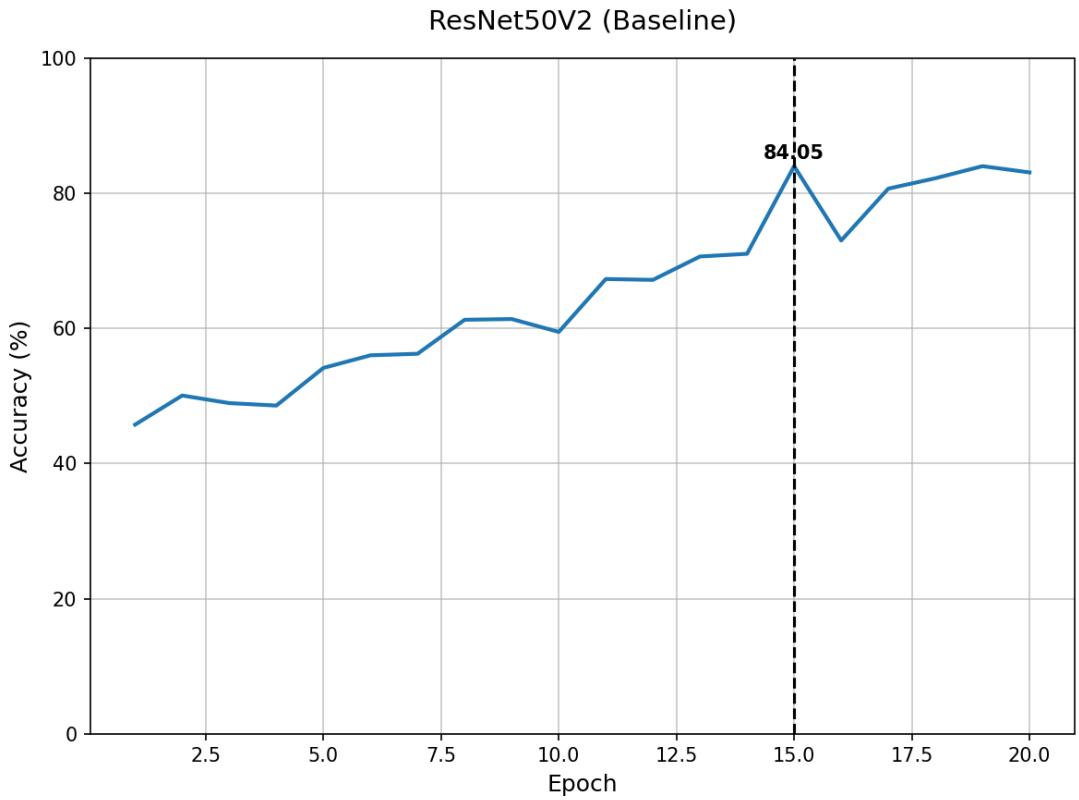

แบบจำลอง(Architecture)	ค่าความแม่นยำสูงสุด(%)	จำนวนรอบ Epoch
EfficientNetV2B0	55.41	20
MobileNetV2	81.89	20
ResNet50V2 (Baseline)	84.05	20
ResNet50V2 (Fine-tuned)	96.42	50

จากตารางที่ 4.2 เป็นการเปรียบเทียบระหว่าง Pre-trained Model จำนวน 3 สถาปัตยกรรม ได้แก่ MobileNetV2, EfficientNetV2B0 และ ResNet50V2 โดยพิจารณาจากค่าความถูกต้อง (Accuracy) สูงสุดและจำนวนรอบ Epoch ที่ใช้ในการฝึกสอน พบว่า ResNet50V2 (Fine-tuned) ให้ผลลัพธ์ที่ดีที่สุดโดยมีค่า Accuracy สูงสุดเท่ากับ 96.42% อย่างไรก็ตาม หากพิจารณาในแง่ของความเร็วในการประมวลผลระยะเริ่มต้น MobileNetV2 สามารถทำผลงานได้คงที่ในเวลาที่สั้นกว่า แต่ผลลัพธ์ที่ได้ยังไม่เพียงพอต่อความต้องการที่ต้องการความแม่นยำสูงในระดับการตรวจสอบความปลอดภัยของยางรถยนต์

ในขณะที่ EfficientNetV2B0 ให้ค่า Accuracy ต่ำที่สุดที่ 55.41% แม้จะมีการปรับจูนพารามิเตอร์ ซึ่งผลลัพธ์นี้อาจไม่เหมาะสมสำหรับปัญหาที่มีความซับซ้อนของพื้นผิววัตถุสูงในงานนี้ ส่วน ResNet50V2 แบบ Fine-tuningรายละเอียด มีค่า Accuracy ที่ 96.42% ซึ่งถือว่าอยู่ในระดับที่ยอดเยี่ยมและเป็นที่ยอมรับได้สำหรับการนำไปประยุกต์ใช้งานจริง

จากผลการศึกษา สามารถสรุปได้ว่าการประยุกต์ใช้อัลกอริทึม Deep Learning โดยเฉพาะโมเดล ResNet50V2 ร่วมกับเทคนิค Fine-tuning สามารถเพิ่มความแม่นยำในการจำแนกความเสียหายของยางรถยนต์ได้เป็นอย่างดี ทำให้งานตรวจสอบสภาพยางเป็นไปได้อย่างรวดเร็ว มีประสิทธิภาพ และช่วยลดความผิดพลาดที่เกิดจากการประเมินด้วยสายตาของมนุษย์ได้

4.3.2 ประสิทธิภาพของโมเดลสรุปผลการฝึกสอน (Model Training Stability)

ผู้วิจัยได้นำโมเดลที่ผ่านการเลือกสรรแล้วมาวิเคราะห์กราฟแนวโน้มความแม่นยำ ดังภาพที่ 4.8 และประเมินความเสถียรของโมเดล (Stability) ตลอดช่วงการฝึกสอน ดังแสดงในตารางที่ 4.3

ช่วงการฝึกสอน (Epochs)	Accuracy โดยเฉลี่ย	ความแปรปรวน (Variance)	สถานะความเสถียร
0 - 10	85.20%	สูง	ช่วงเริ่มต้นการเรียนรู้ โมเดลกำลังปรับตัว
11 - 20	91.55%	ปานกลาง	โมเดลเริ่มเรียนรู้ลักษณะเฉพาะของยางชำรุดได้ดีขึ้น
21 - 30	94.10%	ต่ำ	ความแม่นยำเพิ่มขึ้นอย่างต่อเนื่อง การสูญเสีย (Loss) ลดลง
31 - 40	95.80%	ต่ำมาก	โมเดลเริ่มลู่เข้าสู่จุดสมดุล (Convergence)
41 - 50	96.42%	เสถียรภาพสูงสุด	โมเดลมีความเสถียร ไม่เกิด Overfitting อย่างรุนแรง

ตารางที่ 4.3 แสดงความเสถียรของโมเดล ResNet50V2 ระหว่างการฝึกสอน (Epoch 10-50)

จากตารางที่ 4.3 และภาพที่ 4.8 แสดงให้เห็นว่าโมเดล ResNet50V2 มีพัฒนาการด้านความแม่นยำที่ดีและมีความแปรปรวนที่ลดลงอย่างมีนัยสำคัญเมื่อจำนวนรอบการฝึกสอนเพิ่มขึ้น จนเข้าสู่สภาวะเสถียรในช่วง Epoch ที่ 40-50 ซึ่งชี้ให้เห็นว่าโมเดลมีความทนทานและเหมาะสมต่อการนำไปใช้งานจริง

ภาพที่ 4.8 กราฟประวัติการฝึกสอน (Training History - Accuracy & Loss)

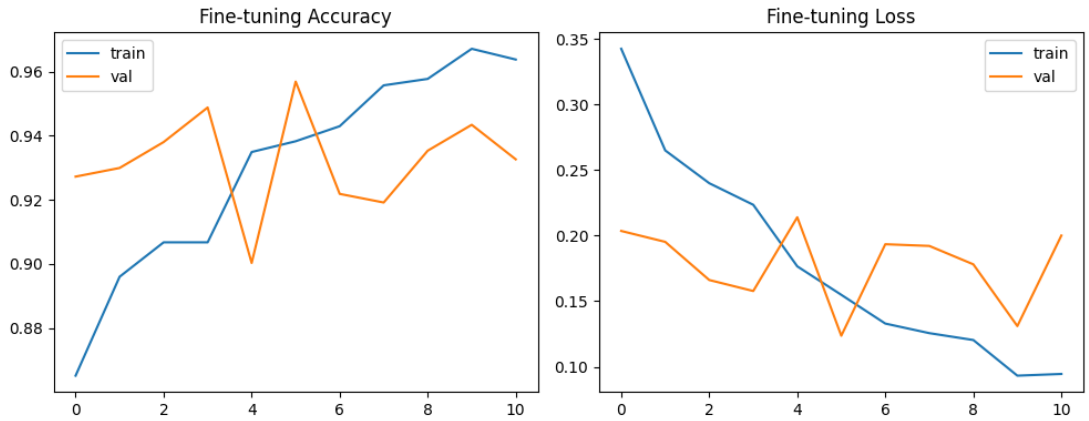

4.2.3 การวิเคราะห์ความแม่นยำรายคลาส (Classification Report)

ผู้วิจัยได้วิเคราะห์ประสิทธิภาพเชิงลึกในแต่ละคลาส เพื่อวัดความแม่นยำในการจำแนก ดังตารางที่ 4.4

ตารางที่ 4.4 ค่าประสิทธิภาพการจำแนกภาพ (Precision, Recall, F1-score)

ประเภทภาพ (Class)	ความแม่นยำ (Precision)	ความระลึก (Recall)	ค่าคะแนน F1 (F1-score)
ยางชำรุด (Defective)	0.99	0.90	0.94
ยางสภาพดี (Good)	0.89	0.99	0.94
ค่าเฉลี่ยรวม (Accuracy)	-	-	0.94 (94.07%)

4.3.4 การวิเคราะห์ความแม่นยำด้วย Confusion Matrix

โมเดลสามารถจำแนกระหว่างยางสภาพดี (Good) และยางที่ชำรุด (Defective) ได้อย่างแม่นยำ ดังภาพที่ 4.9

ภาพที่ 4.9 ตารางวิเคราะห์ความผิดพลาด (Confusion Matrix)

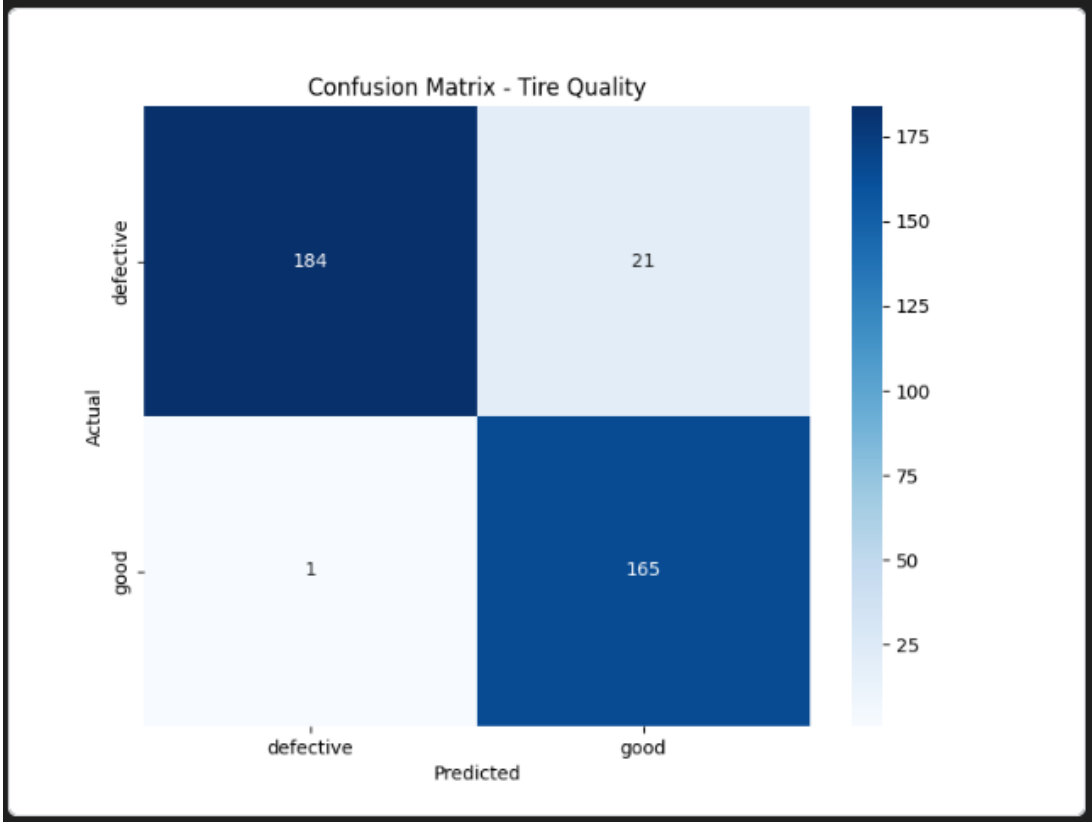

Confusion Matrix

ผลการทดลองประสิทธิภาพแบบจำลองและส่วนติดต่อผู้ใช้งาน

……